Verilerin Düzenlenmesi, Sınıflandırılması ve Analizi

Verilerin Düzenlenmesi

Tablo 2. İstatistik Final Sınavı Notlarının Küçükten Büyüğe Doğru Basit Veri Olarak Sunumu

Numarası	Not	Numarası	Not	Numarası	Not	Numarası	Not
6	40	14	60	12	70	13	80
1	50	19	60	15	70	18	80
16	50	2	70	20	70	9	90
4	60	8	70	5	80	17	90
11	60	10	70	7	80	3	100

- **En büyük değer (X_{max}):** Veri kümesinin en büyük değeridir. Örneğimiz için $X_{max} = 100$ olur
- **En Küçük değer (X_{min}):** Veri kümesinin en küçük değeridir. Örneğimiz için $X_{max} = 40$ olur.
- **Range (Değişim Aralığı):** En Büyük Değer - En Küçük Değer'i ifade eder. Önreğimiz için bu değer $100 - 40 = 60$.

Basit Veriyi Sınıflandırma

- **Sınıf:** Eşit ya da birbirine yakın değere sahip verilerin bir arada gösterilmesiyle oluşturulan her bir gruba sınıf denir. Sınıf sayısı k ile hesaplanır.

Örnek: 500 öğrenci istatistik dersini almıştır. Bu öğrencilerin yılsonu not ortalaması 0 ile 100 değerleri arasında değişmektedir. Öğrencilerin yılsonu not ortalamasının çoğunlukla birbirinden farklı ama birbirine yakın olacağı düşünülürse sınıflanmış veri şeklinde sunulabilir.

Başarı Derecesi	Not Sınıfları (Gruplar)	Sınıf Orta Değeri (m_i)	Öğrenci Sayısı (Frekansı)	Kümülatif Sıklık
AA	90-100	95	50	50
BA	85-89	87	60	110
BB	80-84	82	40	150
CB	75-79	77	50	200
CC	70-74	72	100	300
DC	60-69	64,5	50	350
DD	50-59	54,5	60	410
DF	40-49	44,5	40	450
FF	0-39	19,5	50	500
Toplam			$\sum_{i=1}^{n} fi = 500$	

Tablo'dan görüldüğü gibi öğrencilerin notları 9 kategoride toplandığı için sınıf sayısı 9'dur $(k = 9)$

- **Sınıfın Alt Sınırı:** Bir sınıfta yer alan en küçük değerdir. Önreğimize göre AA için alt sınır 90'dır.
- **Sınıfın Üst Sınırı:** Bir sınıfta yer alan en büyük değerdir. Örneğimize göre AA için üst sınır 100'dür.
- **Sınıf Aralığı:** İki ardışık sınıfın alt ya da üst değerlerinin biribirinden çıkartılmasıyla bulunur.
  - Örneğin; A sınıfı [79,75], B sınıfı [74,70] olsun. Aralığı bulmak için iki ardışık sınıfın alt sınırlarını ya da üst sınırlarını birbirinden çıkartırız: $79 - 74 = 75 - 70 = 5$ olur.
  - Eğer sınıfların kendi içinde üst sınırından alt sınırını çıkartsaydık sonuç 4 olurdu ve bu bize sınıf büyüklüğünü/uzunluğunu verirdi.
  - Bu yöntem sadece **grup genişlikleri birbirine eşit olduğu durumda** geçerlidir. Diğer durumlarda önceki maddedeki sınıf büyüklüğü sınıf aralığı olarak kullanılır.
- **Sınıf Orta Değeri (m_i):** Bir sınıfın alt ve üst sınır değerlerinin ortalaması o sınıfın orta değerini verir. Her bir sınıf için sınıf orta değerlerini aşağıdaki formül yardımıyla bulunabilir:

$$m_i = \frac{\text{Sınıfın Üst Sınırı}_i + \text{Sınıfın Alt Sınırı}_i}{2} \ , \ i = 1, 2, 3, 4, ..., k$$

- **Frekans (Sıklık):** Bir değişkenin aynı değeri için kaç kez tekrarlandığını gösterir. f_i ile ifade edilir.
- **Nispi (Göreli) Frekans:** Veri setinde ilgili sınıfa düşen veri adedinin toplam birim sayısına
  oranıdır.
- **Kümülatif Frekans:** Değişken frekanslarının toplanarak ifade edilmesidir.
- **Kümülatif Nispi Frekans:** Nispi frekansların toplanarak ifade edilmesidir.

- Örnek:

Öğrencilerin Notları	Notların Sıklığı (Frekansı) = f_i	Nispi Frekans	Kümülatif Frekans	Kümülatif Nispi Fekans
40	1	1/20=0.05	1	0.05
50	2	2/20=0.10	3	0.15
60	4	4/20=0.20	7	0.35
70	6	6/20=0.30	13	0.65
80	4	4/20=0.20	17	0.85
90	2	2/20=0.10	19	0.95
100	1	1/20=0.05	20	1
Toplam	$\sum_{i=1}^{n} fi = 20$	1		

- Basit veri, frekansları yazılarak **gruplandırılmış veri** haline getirilmiştir
- En yüksek frekans değeri 70 tir. 20 kişilik sınıfta 6 öğrenci istatistik dersi final sınavından 70 almıştır.
- En düşük frekansa ise 40 ve 100 değerleri sahiptir. Sınıfta 1'er öğrenci final sınavından 40 ve 100 almıştır.

Sınıf Aralığının Belirlenmesi

Sınıf aralıkları araştırmacılar tarafından farklı yöntemlerle belirlenebilmektedir. Bunlardan biri de <u>örneklem genişliğini</u> esas alan yaklaşımdır.

$$\text{Sınıf Aralığı} = \frac{X_{max} - X_{min}}{\sqrt{n}}$$
$$\text{n : Veri Adedi} \Rightarrow \sqrt{n} : \text{Sınıf Sayısı}$$

$\sqrt{n}$ kökten çıkartıldığında tam sayı değilse en yakın tam sayıya yuvarlanır. Örneğin; $\sqrt{300} = 17,5$ değeri 17 değerine yuvarlanır.

Frekans Dağılım Tablolarının Hazırlanması

1. Veriler sayılarak küçükten büyüğe sıralanır.
2. Range hesaplanır. (En büyük değer - En küçük değer)
3. Sınıf sayısı belirlenir ($\sqrt{n}$) ve sınıf aralığı hesaplanır.
4. Sınıfların başlangıç noktaları belirlenir. İlk sınıfın alt değeri en küçük sayıdan daha küçük ve bu
   sayıyı içerecek şekilde belirlenir.
5. Her sınıfa düşen veri adedi sayılır ve frekans dağılımı oluşturulur.

Dipnot

Veri Grubu: Aynı değere sahip verilerin birleştirilerek ifade edilmesidir.

Veri Sınıfı: Aynı veya yakın değere sahip verilerin tek başlık altında ifade edilmesidir.

Tanımlayıcı İstatistikler

Tanımlayıcı istatistikler 4 başlık altında incelenir:

1. Merkezi Eğilim Ölçüleri (Konum/Yer Ölçüleri)

1.1 Aritmatik Ortalama

- Gözlem değerlerinin toplamının denek sayısına bölünmesiyle bulunur.
- Kitle ortalaması **μ**, örneklem ortalaması ise $\bar{X}$ ile gösterilir.

1.1.1 Sıklık Çizgileri için Ortalama (Gruplanmış Veriler İçin)

- Spesifik veri grubunun frekansının grubun değeriyle çarpılıp toplam frekansa bölünmesiyle bulunur.

- Aslında gruptaki verilerin tamamının toplamını toplam kişi sayısına bölüyon başka bir şey değil, orijinal tanımla aynısı.

1.1.2 Sınıflandırılmış Verilerde Ortalama

- Sınıflanmış verilerde sınıfların değerleri bilinmediğinden **sınıf orta noktaları** hesaplamada kullanılır.

$$m_i = \frac{\text{Sınıf Alt Sınırı} + \text{Sınıf Üst Sınırı}}{2}$$

- Bundan sonra gruplanmış veride yapıldığı gibi frekans ve m_i çarpılıp toplam frekansa bölünerek sınıfın ortalamasına ulaşılabilir.

1.2 Mod (Tepe Değer)

- Bir veri setinde en çok tekrar eden, yani frekansı en yüksek olan değer(ler)dir.
- Veri setinin modu olmayabileceği gibi birden fazla modu da olabilir.

1.2.1 Gruplanmış Veriler için Mod

- Gruplanmış verilerde en yüksek frekansa karşılık gelen gözlem değeri verinin modunu
  vermektedir.

1.2.2 Sınıflanmış Verile için Mod

- Sınıflanmış verilerin modunu bulmak için öncelikle mod sınıfı bulmak gerekir. Mod sınıf frekansı en yüksek olan sınıftır.
- Mod sınıf belirlendikten sonra modun tam değerini bulmak için aşağıdaki formül kullanılır.

$$\text{Mod} = I_{\text{alt}} + \frac{\triangle_1}{\triangle_1 + \triangle_2} \cdot s$$

I_{alt} : Mod sınıfın alt sınırı

s : Sınıf aralığı

$\triangle_1$:
Mod sınıfın frekansı ile bir önceki sınıfın frekansı arasındaki mutlak fark

$\triangle_2$:
Mod sınıfın frekansı ile bir sonraki sınıfın frekansı arasındaki mutlak fark

❗ Bir önceki sınıf $(\triangle_1)$ değer olarak mod sınıftan küçük olan sınıftır.

❗ Bir sonraki sınıf $(\triangle_2)$ değer olarak mod sınıftan büyük olan sınıftır.

- **Örnek**: Önceki örnek için mod değeri hesaplayalım.

Başarı Derecesi	Not Sınıfları (Gruplar)	Sınıf Orta Değeri m_i	Öğrenci Sayısı (Frekansı)f_i
AA	90-100	95	50
BA	85-89	87	60
BB	80-84	82	40
CB	75-79	77	50
CC	70-74	72	100
DC	60-69	64,5	50
DD	50-59	54,5	60
DF	40-49	44,5	40
FF	0-39	19,5	50

I_{alt} : 70
$I_{üst}$: 74

s : 74 - 70 = 4

Δ_1 : 100 – 50 = 50
Δ_2 : 100 – 50 = 50

$$Mod = I_{alt} + \frac{\Delta_1}{\Delta_1 + \Delta_2} . s = 70 + \frac{50}{50+50} . 4 = 72$$

1.3 Medyan (Ortanca)

- Küçükten büyüğe sıralanmış veri setinin ortasındaki değerdir.
- Setteki eleman sayısı çift ise ortadaki 2 elemanın aritmatik ortalaması medyan olur.
- n sayıda eleman içeren bir veri setinde X değişkeninin medyanı;
  - n tek sayı ise ➢ $\frac{n+1}{2}$'nci eleman (yani ortanca eleman)
  - n çift sayı ise ➢ $\frac{n}{2}$'nci eleman ile $\frac{n}{2} + 1$'nci elemanın ortalamasıdır.

1.3.1 Gruplanmış Veriler için Medyan

- Ortadaki veriyi bulabilmek için kümülatif frekans kullanılır.

- Kümülatif frekansın teklik çiftliğine göre yukarıdaki işlemler uygulanarak medyan olan grup değeri bulunur.

1.3.2 Sınıflanmış Veriler için Medyan

- Sınıflanmış verilerde medyan değeri hesaplanırken ilk olarak medyan sınıfı belirlenir. Medyan sınıfı
  birikimli frekanslar dikkate alındığında toplam frekansın yarısını içinde bulunduran sınıftır.
- Medyan sınıf bulunduktan sonra aşağıdaki formül kullanılarak medyan değere ulaşılır:

$$\text{Med}_{alt} = I_{alt} + \frac{\frac{n}{2} - \sum_{i=t}^{m} f_i}{f_m} \cdot s$$

I_{alt} : Medyan sınıfının alt sınırı

s : Sınıf aralığı

$\frac{n}{2}$: Gözlem sayısının yarısı (Medyan pozisyonu)

f_m : Medyan sınıfının frekansı

$\sum_{i=t}^{m-1} f_i$: Medyan sınıfından önceki frekansların toplamı

- **Örnek**: Önceki örnek için medyanını hesaplayınız.

Başarı Derecesi	Not Sınıfları (Gruplar)	Sınıf Orta Değeri m_i	Öğrenci Sayısı (Frekansı) f_i	Kümülatif Frekans
AA	90-100	95	50	50
BA	85-89	87	60	110
BB	80-84	82	40	150
CB	75-79	77	50	200
CC	70-74	72	100	300
DC	60-69	64,5	50	350
DD	50-59	54,5	60	410
DF	40-49	44,5	40	450
FF	0-39	19,5	50	500
Toplam			$\sum_{i=1}^{n} f_i = 500$	

Medyan $\frac{n}{2} = \frac{500}{2}$ = 250'inci gözleme düşmektedir.

I_{alt} : 70 $\quad I_{üst}$: 74 $\quad s$: 74 - 70 = 4

f_m : 100 $\quad \sum_{i=t}^{m-1} f_i$: 200

$\sum_{i=m+1}^{k} f_i$: 200

$$Med = I_{alt} + \frac{\frac{n}{2} - \sum_{i=t}^{m-1} f_i}{f_m} . s$$

$$Med = 70 + \frac{250-200}{100} . 4 = 72$$

1.3 Çeyreklik ve Yüzdelikler

- Bir veri setini 4 eşit parçaya ayıran değerlere çeyreklikler (Q_1, Q_2, Q_3, Q_4), yüz parçaya ayıran değerlere ise yüzdelik denir.
- İkinci çeyreklik (Q_2) ve 50. yüzdelik ortancaya karşılık gelir.
- Veri setinin büyüklüğü n ise;

$$Q_x = \frac{x \cdot (n+1)}{4}$$

2. Merkezi Yayılım Ölçüleri

2.1 Değişim Aralığı

- En büyük gözlem değeri ile en küçük gözlem değerinin farkıdır.

$$R = X_{max} - X_{min}$$

2.2 Varyans ve Standart Sapma

- Veri setindeki her bir değerin standart sapmadan farklarının karelerinin toplamının örneklem genişliğinin bir eksiğine bölünmesiyle oluşan değere **örneklem varyansı**, karekökü alınan varyansa ise **standart sapma** denir.
- Ana kütlenin varyansı σ^2, standart sapması σ ile gösterilir. Örneklemin varyansı s^2 ve standart sapması s simgesi ile gösterilir.
- Verilerin varyansı, dolayısıyla standart sapması arttıkça verilerin yayılımı artmaktadır.
- Varyans ve standart sapma her zaman pozitif bir değerdir

2.2.1 Gruplanmış Veriler için Varyans ve Standart Sapma

- Orijinalinin aynısı, sadece her grup değerinin ortalamadan farkını aldıktan sonra bu farkları kendi frekanslarıyla toplamak gerekiyor.

2.2.2 Sınıflanmış Veriler için Varyans ve Standart Sapma

- Sınıflanmış değerlerde sınıfların gruplardaki gibi değerleri belli olmadığı için sınıf orta değerleri kullanılır. (m_i)

2.3 Değişim Katsayısı

- Birden fazla ana kütle üzerinde, aynı değişkenlerle yapılan deneylerin değerlerinin karşılaştırılmasında kullanılır.
- Standart sapmayı, ortalamanın yüzdesi olarak ifade eder.

$$\text{Kitle İçin} = \frac{\sigma}{\mu} \cdot 100$$
$$\text{Örneklem İçin} = \frac{s}{\bar{X}} \cdot 100$$

- Göreli (relative) değişkenliği ölçer.
- (%) olarak yorumlanır.
- Ortalamaya göre yüzde kaçlık bir değişim gösterdiğini ifade etmeden kullanılır.

2.4 Çarpıklık

- Bir değişkenin merkezi eğilim ölçülerinin birbirlerine göre konularıdır.

2.4.1 Simetrik Dağılım

- Aritmetik ortalama, medyan ve mod birbirine eşittir.
- Çarpıklık değeri '0'dır.
- Normal dağılım için çarpıklık değerinin 0 olması gerekmektedir.

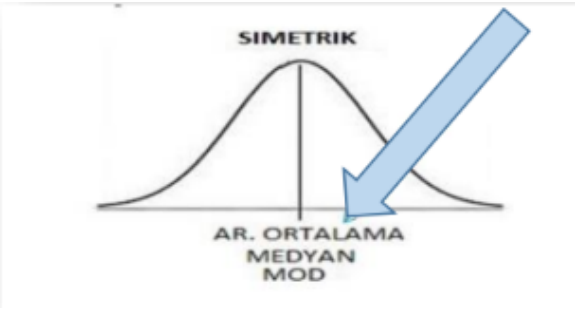

2.4.2 Sola Çarpık Dağılım (Negatif Çarpıklık)

- Soldaki kuyruk daha uzundur.
- Dağılımın kütlesi grafiğin sağ tarafında yoğunlaşmıştır.
- Mod > Medyan > Aritmetik Ortalama ilişkisi vardır.

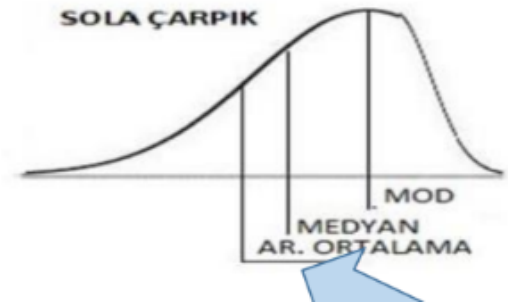

2.4.3 Sağa Çarpık Dağılım (Pozitif Çarpıklık)

- Sağdaki kuyruk daha uzundur.
- Dağılımın kütlesi grafiğin sol tarafında yoğunlaşmıştır.
- Aritmetik Ortalama > Medyan > Mod ilişkisi vardır.

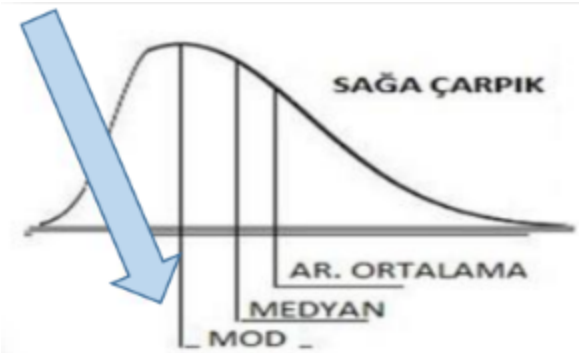

2.5 Basıklık

- Değilim genişliğini yorumlamak için kullanılır.
- Normal dağılım simetriktir ve basıklık katsayısı değeri sıfırdır.
- Basıklık katsayısı sıfırdan küçük ise dağılım basıktır.
- Basıklık katsayısının sıfırdan büyük ise dağılım sivri bir dağılımdır.

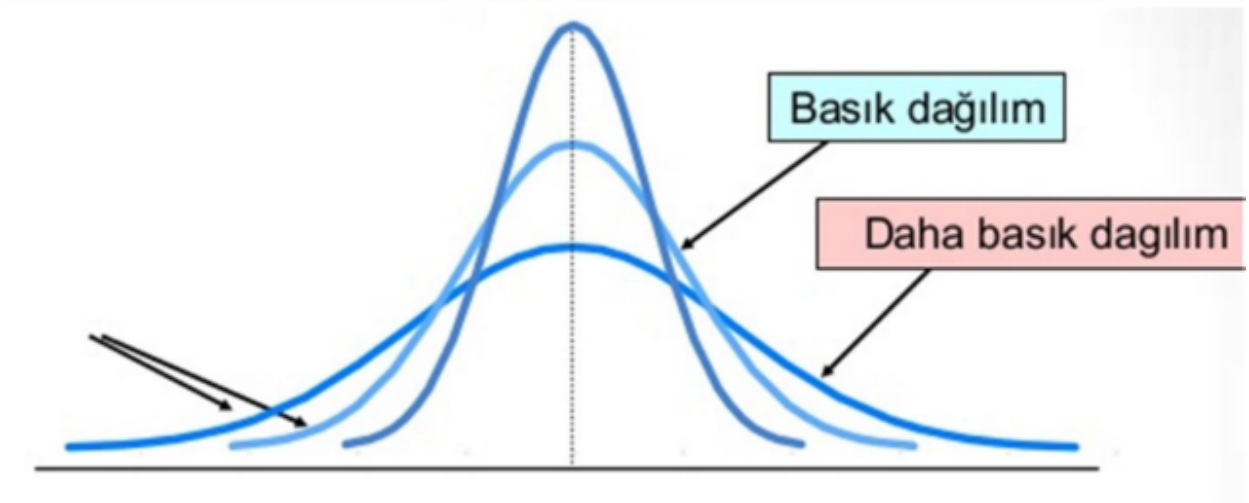

About @Me

Mertcan Gündoğan LinkedIn Profile

Mertcan (@mertcangndn) • Instagram profile

61 Followers, 109 Following, 10 Posts - See Instagram photos and videos from Mertcan (@mertcangndn)

https://www.instagram.com/mertcangndn/

Mertcangndn - Overview

Mertcangndn has 14 repositories available. Follow their code on GitHub.

https://github.com/Mertcangndn